4. Основы метода наименьших квадратов (МНК)

4.1. Принцип МНК

Простейшая линейная регрессия
Постановка задачи

Постановка задачи:

Есть экспериментальные данные (наблюдения), полученные парами (x_1,y_1), (x_2,y_2), …, (x_n,y_n). Например, рост человека *x* и его вес *y*.

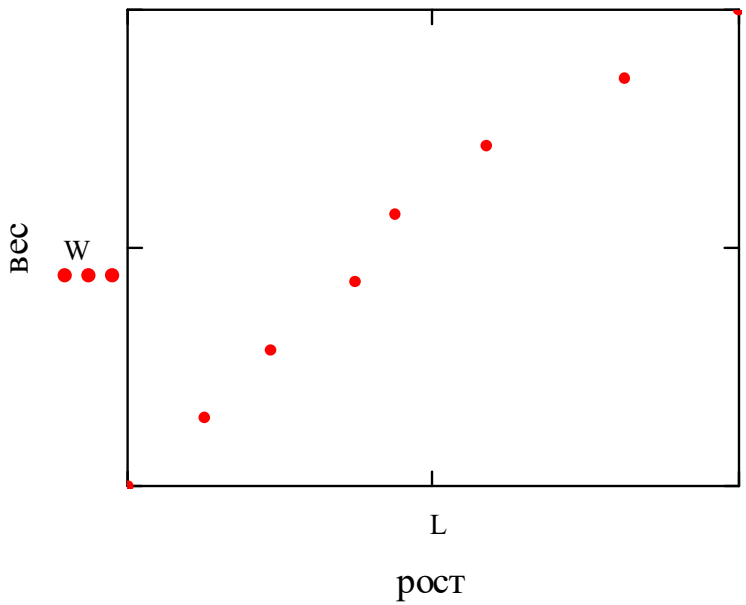

Есть зависимость между ростом и весом? Есть корреляция? Коэффициент корреляции?

Как описать зависимость с точки зрения статистики?

Опишем как изменяется математическое ожидание одной величины от значения другой величины? Такая зависимость называется линией регрессии одной величины на другую

В примере: Пусть величина *y* *(выберем вес)* будет наблюдаемой случайной величиной, *x* *(рост)* — фиксированной

Простейшая линейная регрессия
Предположения

Простейшая модель регрессии зависимости (условного математического ожидания y) будет линейной:

$E(y_i/x_i)= ax_i+b$

Рассматриваем случайную величину y_i как величину, зависящую от x_i и зависимость эта линейна.

При этом величины y_i измерены с погрешностью ε_i, поэтому при измерениях

$y_i = ax_i+b+ \varepsilon_i$.

Предположения

Случайная величина погрешность ε_i. $\sim N(0, \sigma^2)$, причем дисперсии для разных i одинаковы и равны σ^2.

→

Тогда y_i являются также случайными нормальными величинами с параметрами $y_i \sim N(ax_i+b, \sigma^2)$

→

Математическое ожидание величины y_i

$E(y_i) = ax_i+b$.

Простейшей линейной регрессии Формулировка искомых параметров

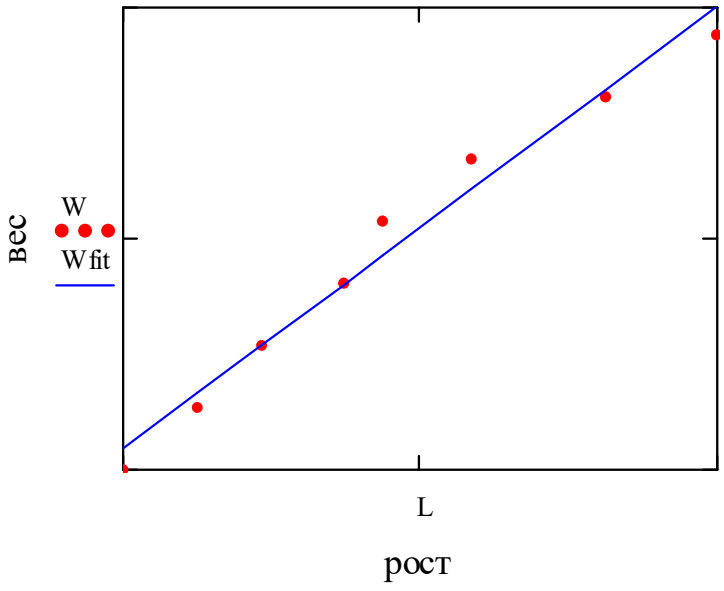

Ожидаемое значение $E(y_i)$ *(математическое ожидание в точке* x_i *– условное математическое ожидание* y *при условии значения* x_i*- линия регрессии)*

аппроксимируется (подгоняется) как линейная зависимость ax_i+b.

a *и* b*- параметры регрессии.*

В задачах регрессии надо найти a *и* b

В эксперименте имеем измеренное в точке x_i *значение* $y_{i\ изм}$ *– значение случайной величины y,*

Полагаем, что случайная величина y_i *– имеет нормальное распределение* $N(ax_i+b, \sigma^2)$

Линия регрессии

Пусть ***y=ax+b*** подгоняется под набор экспериментальных данных (пар точек)

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$$

Прямую линии регрессии подгоняем так, чтобы она максимально была близка к экспериментальным точкам.

y_i - (ax_i+b) для всех ***i*** — оценка близости для каждой точки.
Для того, чтобы учесть отклонения во всех точках, надо просуммировать все отклонения.
Предлагается суммировать квадраты отклонений, чтобы суммировать абсолютные значения отклонений.

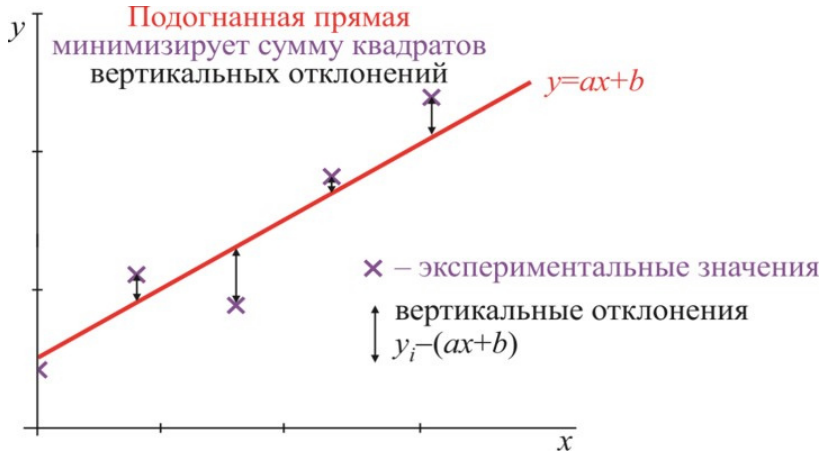

Метод наименьших квадратов: выбираем a и b такими, чтобы сумма квадратов вертикальных отклонений (разница между оцененным значением ***y=ax+b*** на прямой и × – экспериментальным значением y_i) была минимальна

Общий принцип МНК (дисперсии y одинаковы)

Если дисперсии всех *y* одинаковы (не зависят от x), т.е. $\sigma_{yi}^2 = \sigma^2$

Линейный случай

Метод наименьших квадратов (МНК) состоит в поиске таких параметров ***a*** и ***b*** *(параметров условного математического ожидания **y** – регрессии **ax+b**)*,

которые приводят к минимуму функционал ***Q***

$$Q = \sum_{i=1}^{n} (y_i - (ax_i + b))^2 \to \min$$

Общий случай

МНК состоит в поиске параметров $\theta_1, \theta_2, \theta_3 \ldots \theta_r$ функции условного математического ожидания ***y*** – регрессии $f(\theta_1, \theta_2, \theta_3 \ldots \theta_r / x)$,

которые приводят к минимуму функционал ***Q***

$$Q = \sum_{i=1}^{n} (y_i - f(\vec{\theta} / x_i))^2 \to \min$$

МНК и Метод Максимального Правдоподобия

Можно показать, что Метод Наименьших Квадратов идентичен Методу Максимального Правдоподобия

(при условии на нормальность распределения погрешности и линейность зависимости) ,

Если погрешности измерения ε_i распределены нормально с математическим ожиданием 0.

Функция плотности вероятности для СВ погрешность ε

$$f(\varepsilon_i)=\frac{1}{\sqrt{2\pi}\sigma_i}\exp\left[-\frac{\varepsilon_i^2}{2\sigma_i^2}\right]$$

$$E\{\varepsilon_i\}=0\,;\,D\{\varepsilon_i^2\}=\sigma_i^2,$$

Перейдем к СВ – измеряемая величина- y
в случае линейной зависимости от x (a и b- параметры- константы)

$$y_i=ax_i+b+\varepsilon_i$$

Если $\varepsilon\sim N(0,\sigma^2)$, то и $y\sim N(ax+b,\sigma^2)$,
Функция плотности вероятности для СВ y

$$f(y_i)=\frac{1}{\sqrt{2\pi}\sigma_i}\exp\left[-\frac{(y_i-ax_i-b)^2}{2\sigma_i^2}\right]$$

Логарифмическая функция правдоподобия

$$l=-\frac{1}{2}\sum_{i=1}^{n}\frac{(y_i-ax_i-b)^2}{\sigma_i^2}+\text{const}$$

По принципу ММП наилучшими a и b будут такие, которые приведут к максимуму l:

$$l=-\frac{1}{2}\sum_{i=1}^{n}\frac{(y_i-ax_i-b)^2}{\sigma_i^2}+\text{const}\to\max$$

Значит функционал Q должен быть минимальным,

что соответствует принципу МНК

$$Q=\sum_{i=1}^{n}\frac{(y_i-ax_i-b)^2}{\sigma_i^2}\to\min$$

Общий принцип МНК (дисперсии y разные)

Если дисперсии y зависят x, т.е. $\sigma_{yi}^2 = \sigma_i^2$

Линейный случай

Метод наименьших квадратов (МНК) состоит в поиске таких параметров ***a*** и ***b*** *(параметров условного математического ожидания* y *– регрессии* ***ax+b***),

которые приводят к минимуму функционал ***Q***

$$Q = \sum_{i=1}^{n} \frac{(y_i - (ax_i + b))^2}{\sigma_i^2} \to \min$$

Общий случай

МНК состоит в поиске параметров $\theta_1, \theta_2, \theta_3 \ldots \theta_r$ функции условного математического ожидания ***y*** – регрессии $f(\theta_1, \theta_2, \theta_3 \ldots \theta_r / x)$,

которые приводят к минимуму функционал ***Q***

$$Q = \sum_{i=1}^{n} \frac{(y_i - f(\vec{\theta} / x_i))^2}{\sigma_i^2} \to \min$$