4. Основы метода наименьших квадратов (МНК)

4.2. Скалярная формула линейного МНК

Постановка задачи МНК

Есть набор экспериментальных данных (пар точек)

$$(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$$

Предполагаем линейную зависимость ***y*** от ***x***: ***y=ax+b***

Прямую линии регрессии подгоняем так, чтобы она максимально была близка к экспериментальным точкам.

Задача:

найти оценки $\tilde{a}$ и $\tilde{b}$

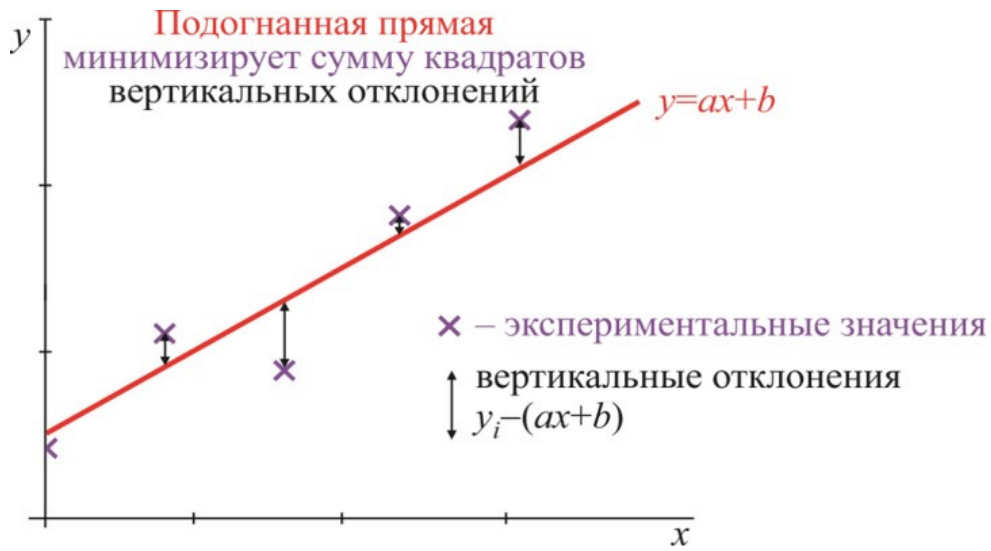

МНК для линейной зависимости ММП

Понятие «близко» очень спорно в математическом понимании.

С другой стороны, можно показать, что метод наименьших квадратов идентичен методу максимального правдоподобия (ММП), если:

- погрешности измерения $\varepsilon_i \sim N(0,\sigma^2)$;
- причем что все дисперсии одинаковы (не зависят от i) и равны σ^2;

плотность вероятности случайной величины – погрешность измерения ε

$$f(\varepsilon)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\varepsilon^2/2\sigma^2}.$$

функция правдоподобия для ε

$$L(\varepsilon)=\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\sum_{i=1}^{n}\varepsilon_i^2/2\sigma^2}.$$

по принципу максимального правдоподобия $L(\varepsilon)$ должна быть максимальна, а значит

$$L(\varepsilon)\to\max$$
$$\sum_{i=1}^{n}\frac{\varepsilon_i^2}{2\sigma^2}\to\min$$

для линейной зависимости y от x

$$\tilde{y}=\tilde{a}x_i+\tilde{b}$$

погрешность измерения ε

$$\varepsilon_i=y_i-\tilde{y}=y_i-(\tilde{a}x_i+\tilde{b})$$

принцип ММП

превращается в принцип МНК:

ищем $\tilde{a}$ и $\tilde{b}$ такие, что

$$L(\varepsilon)\to\max$$
$$\sum_{i=1}^{n}\frac{(y_i-(\tilde{a}x+\tilde{b}))^2}{2\sigma^2}=\sum_{i=1}^{n}(y_i-(\tilde{a}x+\tilde{b}))^2\to\min$$

Поиск минимума Q

По принципу МНК надо найти минимум ***Q***.
Для поиска минимума приравняем к нулю первые частные производные по параметрам ***a*** и ***b***.

$$\begin{cases} \dfrac{\partial Q}{\partial b} = 0 \\ \dfrac{\partial Q}{\partial a} = 0 \end{cases}$$

$$\begin{cases} \dfrac{\partial Q}{\partial b} = -2\sum_{i=1}^{n}\left(y_i - b - ax_i\right) = 0 \\ \dfrac{\partial Q}{\partial a} = -2\sum_{i=1}^{n} x_i\left(y_i - b - ax_i\right) = 0 \end{cases}$$

$$\begin{cases} \sum_{i=1}^{n} y_i - nb - a\sum_{i=1}^{n} x_i = 0 \\ \sum_{i=1}^{n} x_i y_i - b\sum_{i=1}^{n} x_i - b\sum_{i=1}^{n} x_i^2 = 0 \end{cases}$$

$$\begin{cases} bn + a\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} y_i \\ b\sum_{i=1}^{n} x_i + a\sum_{i=1}^{n} x_i^2 = \sum_{i=1}^{n} x_{i1} y_i \end{cases}$$

Решение уравнения и оценки $\tilde{a}$ и $\tilde{b}$

Получаем решение уравнения – значения оценок для $\tilde{a}$ и $\tilde{b}$.

Оценки $\tilde{a}$ и $\tilde{b}$ являются оценками линейной регрессии, наилучшими с точки зрения принципов МНК.

$$\begin{cases} \tilde{a} = \dfrac{\sum_{i=1}^{n} x_i y_i - \dfrac{\sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n}}{\sum_{i=1}^{n} x_i^2 - \dfrac{\left(\sum_{i=1}^{n} x_i\right)^2}{n}} \\ \tilde{b} = \dfrac{\left(\sum_{i=1}^{n} y_i\right)}{n} - a\left(\dfrac{\sum_{i=1}^{n} x_i}{n}\right) \end{cases}$$

Частный случай: два измерения (скалярная запись)

Произведено **два измерения** для определения коэффициентов ***a*** и ***b*** в линейной зависимости ***(x₁,y₁),(x₂,y₂)***.
Имеем систему из двух уравнений для определения **двух неизвестных *a* и *b*** .

$$\boxed{\begin{aligned} y_1 &= ax_1 + b \\ y_2 &= ax_2 + b \end{aligned}}$$

Решение должно быть единственным и оно известно из линейной алгебры.
По двум точкам проводим прямую линию (ищем $\tilde{a}$ и $\tilde{b}$)

Проверим, даст ли решение, известное из линейной алгебры МНК.

Применим формулу МНК и видим, что ответы линейной алгебры и МНК совпадают.

$$\boxed{\begin{cases} \tilde{a} = \dfrac{\sum_{i=1}^{n} x_i y_i - \dfrac{\sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n}}{\sum_{i=1}^{n} x_i^2 - \dfrac{\left(\sum_{i=1}^{n} x_i\right)^2}{n}} = \dfrac{x_1 y_1 + x_2 y_2 - \dfrac{(x_1 + x_2)(y_1 + y_2)}{2}}{(x_1^2 + x_2^2) - \dfrac{(x_1 + x_2)^2}{2}} = \dfrac{y_1 - y_2}{x_1 - x_2} \\ \tilde{b} = \dfrac{\left(\sum_{i=1}^{n} y_i\right)}{n} - a\left(\dfrac{\sum_{i=1}^{n} x_i}{n}\right) = \dfrac{(y_1 + y_2) - (x_1 + x_2)a}{2} \end{cases}}$$

Средства Mathcad для линейной регрессии

Задано:
Vx- вектор значений ***x***,
Vy- вектор значений ***y***.

Найти:
оценки $\tilde{a}$ и $\tilde{b}$

Встроенные функции ***MathCad***

Line(***Vx,Vy***) – выводит вектор коэффициентов $(\tilde{b}, \tilde{a})$

Intercept(***Vx,Vy***) – выводит $\tilde{b}$.

Slope(***Vx,Vy***) – выводит $\tilde{a}$.