7. Многомерная линейная регрессия

Линейная зависимость y от двух факторов x_1, x_2

Исследуемая физическая величина ***y*** может зависеть не от одного фактора ***x***, а от нескольких одновременно. Здесь очень важна одновременность зависимости, анализ надо проводить сразу по нескольким факторам и искать параметры связи ***y*** и нескольких ***x*** одновременно.

При линейной зависимости ***y*** от двух ***x*** ***(x_1 и x_2)*** можно представить эту зависимость на графике в виде плоскости ***$y(x_1, x_2)$***.

$$y = x_1\theta_1 + x_2\theta_2 + \theta_0$$

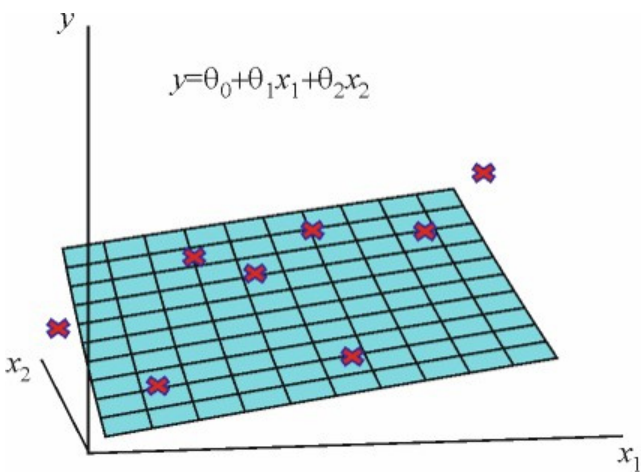

✖ — *экспериментальные значения y;*
x_1, x_2 – факторы, определяющие y.
Двухфакторная линейная регрессия.
В МНК для поиска θ_0, θ_1, θ_2 ищется минимум

$$Q = \sum_{i=1}^{n}\left(y_i - (\theta_0 + \theta_1 x_{1_i} + \theta_2 x_{2_i})\right)^2$$

СЛАУ для оценки параметров ***θ_0, θ_1*** и ***θ_2*** по результатам ***n*** измерений y с погрешностями ***ε*** будет выглядеть так:

$$\begin{cases} y_1 = \theta_0 + x_{11}\theta_1 + x_{12}\,\theta_2 + \varepsilon_1 \\ y_2 = \theta_0 + x_{21}\theta_1 + x_{22}\theta_2 + \varepsilon_2 \\ \dots\dots\dots\dots\dots\dots\dots\dots\dots\dots \\ y_n = \theta_0 + x_{n1}\theta_1 + x_{n2}\theta_2 + \varepsilon_n \end{cases}$$

Линейная зависимость от нескольких факторов. СЛАУ для оценки параметров

Пусть факторов будет ***r***, т.е. есть набор $x_1, x_2, x_3, \ldots, x_r$,

тогда и коэффициентов линейной зависимости будет ***r***: $\theta_1, \theta_2, \ldots, \theta_r$.

x_{ij} – известные величины ***j***-того фактора, определяющие ***i***-й номер эксперимента.

Предполагаемая зависимость измеряемой величины ***y*** от факторов ***x*** будет выглядеть так:

$$y = x_1\theta_1 + x_2\theta_2 + \ldots + x_r\theta_r$$

Используя результаты измерения

y с погрешностями ***ε***

Можно построить систему линейных уравнений для оценки $\theta_1, \theta_2, \ldots, \theta_r$. :

$$\begin{cases} y_1 = x_{11}\theta_1 + x_{12}\theta_2 + \ldots + x_{1r}\theta_r + \varepsilon_1 \\ y_2 = x_{21}\theta_1 + x_{22}\theta_2 + \ldots + x_{2r}\theta_r + \varepsilon_2 \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ y_n = x_{n1}\theta_1 + x_{n2}\theta_2 + \ldots + x_{nr}\theta_r + \varepsilon_n \end{cases}$$

Матричный вид СЛАУ

СЛАУ надо решить относительно $\theta_1, \theta_2, \ldots, \theta_r$.

$$\begin{cases} y_1 = x_{11}\theta_1 + x_{12}\,\theta_2 + \ldots + x_{1r}\theta_r + \varepsilon_1 \\ y_2 = x_{21}\theta_1 + x_{22}\theta_2 + \ldots + x_{2r}\theta_r + \varepsilon_2 \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ y_n = x_{n1}\theta_1 + x_{n2}\theta_2 + \ldots + x_{nr}\theta_r + \varepsilon_n \end{cases}$$

Введем обозначения :

$$\vec{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad \mathbf{X} = \begin{pmatrix} x_{11} & \ldots & x_{1r} \\ \vdots & \ddots & \vdots \\ x_{n1} & \ldots & x_{nr} \end{pmatrix}. \quad \vec{\varepsilon} = \begin{Bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{Bmatrix}$$

$$\vec{\theta} = (\theta_1, \theta_2, \theta_3, \ldots \theta_r)$$

СЛАУ в матричном виде

$$\vec{y} = \mathbf{X}\vec{\theta} + \vec{\varepsilon}$$

$$\vec{y} - \vec{\varepsilon} - \mathbf{X}\vec{\theta} = \vec{0}.$$

Принцип МНК для системы r факторов

Для характеристики дисперсий величины ***y*** и зависимости ***y*** друг от друга используем ковариационную матрица ***C***
Для независимых у ковариационная матрица :

$$\mathbf{C}_{\mathbf{y}} = \mathbf{C}_{\varepsilon} = \begin{pmatrix} \sigma_1^2 & \cdots & 0 \\ 0 & \sigma_2^2 & \\ \vdots & & \ddots \\ 0 & \cdots & \sigma_n^2 \end{pmatrix}.$$

Обратная ей матрица называется весовой ***G***:

$$\mathbf{G}_{\mathbf{y}} = \mathbf{G}_{\varepsilon} = \begin{Bmatrix} g_1 & \cdots & 0 \\ \vdots & \ddots & \\ 0 & \cdots & g_n \end{Bmatrix} = \begin{Bmatrix} \frac{1}{\sigma_1^2} & \cdots & 0 \\ \vdots & \ddots & \\ 0 & \cdots & \frac{1}{\sigma_n^2} \end{Bmatrix}$$

По принципу МНК

$$Q = \sum_{i=1}^{n} \frac{(y_i - \tilde{y}_i)^2}{\sigma_i^2} = \sum_{i=1}^{n} \frac{\varepsilon_i^2}{\sigma_i^2} = \vec{\varepsilon}^{\,T} \mathbf{G}_{\mathbf{y}} \vec{\varepsilon} \to \min$$

С учётом введённых обозначений для G_y минимизируемый функционал ***Q*** можно переписать

$$Q = (\vec{y} - \mathbf{X}\vec{\theta})^T \mathbf{G}_{\mathbf{y}} (\vec{y} - \mathbf{X}\vec{\theta}) \to \min$$

Решение МНК для системы r параметров

Для нахождения минимума Q необходимо образовать частные производные по θ_i и приравнять их к 0.

$$\frac{\partial Q}{\partial \theta_i} = 0 \; ; \; i = \overline{1 \ldots r},$$

В матричном виде

$$\frac{\partial Q}{\partial \vec{\theta}} = \frac{\partial \vec{\varepsilon}^{\mathrm{T}}}{\partial \vec{\theta}} \mathbf{G}_{\mathbf{y}} \vec{\varepsilon} + \vec{\varepsilon}^{\mathrm{T}} \frac{\partial}{\partial \vec{\theta}} \left(\mathbf{G}_{\mathbf{y}} \vec{\varepsilon} \right) = \mathbf{X}^{\mathrm{T}} \mathbf{G}_{\mathbf{y}} \vec{\varepsilon} + \vec{\varepsilon}^{\mathrm{T}} \mathbf{G}_{\mathbf{y}} \mathbf{X} = \mathbf{X}^{\mathrm{T}} \mathbf{G}_{\mathbf{y}} \vec{\varepsilon} +$$

$$+ \mathbf{X}^{\mathrm{T}} \mathbf{G}_{\mathbf{y}} \vec{\varepsilon} = 2 \mathbf{X}^{\mathrm{T}} \mathbf{G}_{\mathbf{y}} \vec{\varepsilon} = 2 \mathbf{X}^{\mathrm{T}} \mathbf{G}_{\mathbf{y}} (\vec{y} - x\vec{\theta}) = 0$$

$$\mathbf{X}^{\mathrm{T}} \mathbf{G}_{\mathbf{y}} \vec{y} = \mathbf{X}^{\mathrm{T}} \mathbf{G}_{\mathbf{y}} \mathbf{x} \vec{\theta}.$$

Для получения искомой оценки параметра $\tilde{\vec{\theta}}$ необходимо подействовать оператором $(\mathbf{x}^{\mathbf{T}} \mathbf{G}_{\mathbf{y}} \mathbf{x})^{-1}$

Оценка параметров $\tilde{\vec{\theta}}$ МНК линейный случай

$$\tilde{\vec{\theta}} = (\mathbf{x}^{\mathbf{T}} \mathbf{G}_{\mathbf{y}} \mathbf{x})^{-1} \mathbf{x}^{\mathbf{T}} \mathbf{G}_{\mathbf{y}} \vec{y}$$

Оценка дисперсии оценок параметров

Дисперсия элементов вектора оценок (ковариационная матрица оценок параметров) тоже может быть записана в векторном виде

$$\mathrm{Var}(\tilde{\vec{\theta}}) = \mathbf{C}_{\tilde{\theta}} = \sigma_y^2 (\mathbf{X}^{\mathrm{T}}\mathbf{X})^{-1}.$$

Дисперсию *y* можно оценить, как и в двухмерном случае, суммой квадратов отклонений от выровненной (рассчитанной) поверхности

$$\tilde{\sigma}_y^2 = S_y^2 = \frac{1}{n-r-1}\sum_{i=1}^{n}\left(y_i - \left(\sum_{j=1}^{r} x_{ij}\theta_j\right)\right)^2$$

Тогда оценку ковариационной матрицы параметров можно записать так

$$\mathbf{S}_{\tilde{\boldsymbol{\theta}}}^{\mathbf{2}} = (\mathbf{X}^{\mathrm{T}}\mathbf{X})^{-1} S_y^2.$$

Диагональные элементы этой матрицы есть дисперсии оценок

$$S_{\theta i}{}^2 = \mathbf{C}_{\tilde{\theta}_{i,i}}.$$

Случайная величина

$$\frac{S_y^2}{\sigma_y^2} \sim \chi_{n-r-1}^2$$

Величины

$$\frac{\tilde{\theta}_i}{S_{\theta_i}} \sim t_{n-r-1}$$

могут быть использованы для проверки гипотезы о значимости (отличии от 0) θ.