8. Доверительные интервалы для параметров a и b. Анализ коэффициентов регрессии

8.1 Интервальные оценки параметров a и b в скалярном виде

Анализируем оценку коэффициентов регрессии оценку $\tilde{a}$ и оценку $\tilde{b}$

Есть набор экспериментальных данных: пары точек
$(x_1,y_1),(x_2,y_2)\ldots(x_n,y_n)$

Значения **y** выбраны как результаты измерений (экспериментальные данные).
Значения **x** – выбраны как факторы, определяющие значения каждого **y**
Каждое значение **y_i** измерено с погрешностью **ε_i**
$\varepsilon_i \in N(0, \sigma^2_i)$
Есть предположение, о том, что **x** и **y** связаны линейным образом, т.е.
y=ax+b
Обрабатывая экспериментальные данные с помощью метода наименьших квадратов можно получить <u>оценки</u> $\tilde{a}$ и $\tilde{b}$

$$\begin{cases} \tilde{a} = \dfrac{\sum_{i=1}^{n} x_i y_i - \dfrac{\sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n}}{\sum_{i=1}^{n} x_i^2 - \dfrac{\left(\sum_{i=1}^{n} x_i\right)^2}{n}} \\ \tilde{b} = \dfrac{\left(\sum_{i=1}^{n} y_i\right)}{n} - \tilde{a}\left(\dfrac{\sum_{i=1}^{n} x_i}{n}\right) \end{cases}$$

Случайные величины оценка $\tilde{a}$ и оценка $\tilde{b}$

Оценки $\tilde{a}$ и $\tilde{b}$ являются линейными функциями от СВ **y** – нормально распределенной .

Значит , сами оценки $\tilde{a}$ и $\tilde{b}$ - являются СВ и имеют нормальное распределение .

$$\begin{cases} \tilde{a} = \dfrac{\sum_{i=1}^{n} x_i y_i - \dfrac{\sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n}}{\sum_{i=1}^{n} x_i^2 - \dfrac{\left(\sum_{i=1}^{n} x_i\right)^2}{n}} \\ \tilde{b} = \dfrac{\left(\sum_{i=1}^{n} y_i\right)}{n} - \tilde{a}\left(\dfrac{\sum_{i=1}^{n} x_i}{n}\right) \end{cases}$$

Оценка дисперсии y после оценки математических ожиданий $\tilde{y}$

Каждому значению

y_i сопоставлено рассчитанное (выровненное) значение $\tilde{a}x_i + \tilde{b}$.

$\tilde{a}x_i + \tilde{b}$- есть оценка математического ожидания для **y_i**

Оценка отклонения экспериментальных значений **y_i** от оцененных $\tilde{y}_i$

математических ожиданий (выровненных, подогнанных значений) –

Оцененная дисперсия y

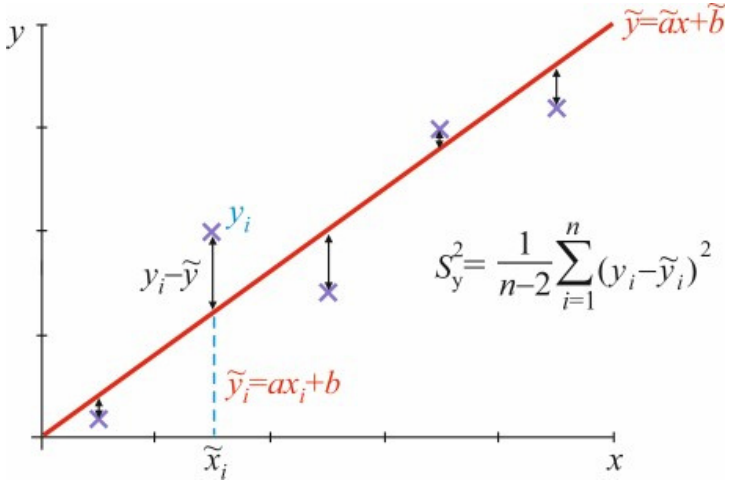

× – выборочные данные y_i; подогнанные (оцененные) значения $\tilde{y}_i$; дисперсия y – мера отклонения y_i от $\tilde{y}_i$

$$S^2{}_y = \frac{1}{(n-2)}\sum_{i=1}^{n}\left(y_i - \tilde{y}_i\right)^2 = \frac{1}{(n-2)}\sum_{i=1}^{n}\left(y_i - (\tilde{a}x_i + \tilde{b})\right)^2$$

для оценки дисперсии **y**

сумму квадратов отклонений делим на **n-2**,

т.к. на основании выборочных данных рассчитали 2 коэффициента $\tilde{a}$ и $\tilde{b}$

Оценка дисперсии y после оценки математических ожиданий $\tilde{y}$

Каждому значению

y_i сопоставлено рассчитанное (выровненное) значение $\tilde{a}x_i + \tilde{b}$.

$\tilde{a}x_i + \tilde{b}$- есть оценка математического ожидания для **y_i**

Оценка отклонения экспериментальных значений **y_i** от оцененных $\tilde{y}_i$ математических ожиданий (выровненных, подогнанных значений) – ***Оцененная дисперсия y***

$$S^2{}_y = \frac{1}{(n-2)}\sum_{i=1}^{n}\left(y_i - \tilde{y}_i\right)^2 = \frac{1}{(n-2)}\sum_{i=1}^{n}\left(y_i - (\tilde{a}x_i + \tilde{b})\right)^2$$

для оценки дисперсии **y**

сумму квадратов отклонений делим на **n-2**,

т.к. на основании выборочных данных рассчитали 2 коэффициента $\tilde{a}$ и $\tilde{b}$

В MathCad для расчета оценённой дисперсии S_y^2 можно использовать встроенную функцию

stderr(x,y)= $\sqrt{s_y^2}$

x- вектор значений определяющих факторов (ось абсцисс)

y- вектор измеренных значений (ось ординат)

Распределение СВ -оцененная дисперсия S^2_y

Оцененная дисперсия S_y^2 - величина, являющаяся функцией СВ y,
и значит оцененная дисперсия S_y^2 - СВ

$$S^2{}_y = \frac{1}{(n-2)}\sum_{i=1}^{n}\left(y_i - \tilde{y}_i\right)^2 = \frac{1}{(n-2)}\sum_{i=1}^{n}\left(y_i - (\tilde{a}x_i + \tilde{b})\right)^2$$

Если

$$\varepsilon_i \sim N(0, \sigma_i^2)$$

тогда можно утверждать, что

$$y_i \sim N(\tilde{a}x_i + \tilde{b}, \sigma_i^2)$$

и по определению СВ, имеющей распределение χ2

$$\sum_{i=1}^{n}\frac{\left(y_i - (\tilde{a}x_i + \tilde{b})\right)^2}{\sigma_i^2} \sim \chi^2_{n-2}$$

$$S_y^2(n-2) \sim \chi^2_{n-2}$$

Интервальная оценка значения дисперсии σ^2_y

если дисперсия всех элементов ***y*** одинакова,
то можно ее оценить из выражения

$$S_y^2 = \sum_{i=1}^{n} \frac{\left(y_i - (\tilde{a}x_i + \tilde{b})\right)^2}{\sigma^2} \sim \chi^2_{n-2}$$

можно выбрать уровень значимости, посчитать квантили распределения χ2 и оценить дисперсию σ^2_y доверительным интервалом

$$\frac{(n-2)S_y^{\ 2}}{\chi^2_{1-\frac{\alpha}{2},n-2}} \le \sigma^2 \le \frac{(n-2)S_y^{\ 2}}{\chi^2_{\frac{\alpha}{2},n-2}}$$

Оценка дисперсии параметра $\tilde{a}$

Ранее (в лекции 4.2) – получили оценку параметра а- $\tilde{a}$
Оценка параметра $\tilde{a}$ - функция от СВ ***y***

$$\tilde{a} = \frac{\sum_{i=1}^{n} x_i y_i - \frac{\sum_{i=1}^{n} x_i \sum_{i=1}^{n} y_i}{n}}{\sum_{i=1}^{n} x_i^2 - \frac{\left(\sum_{i=1}^{n} x_i\right)^2}{n}}$$

Применяя правила расчета дисперсий для функций СВ
Известна ***дисперсия y***- σ^2_y ищем дисперсию оценки $\tilde{a}$ -***var($\tilde{a}$)***

$$var(\tilde{a}) = \frac{\sigma^2_{\tilde{a}\,y}}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{\sigma^2_y}{S_x^{\,2}(n-1)}$$

Дисперсия ***y*** - σ^2_y на самом деле нам не известна, и вместо нее пишем оценку дисперсии ***y***- S^2_y – и получаем оценку дисперсии оценки $\tilde{a}$- $s^2_{\tilde{a}}$

$$S^2_{\tilde{a}} = \frac{S^2_y}{S_x^{\,2}(n-1)}$$

Распределение СВ $\tilde{a}$

Оценка дисперсии СВ $\tilde{a}$ - $S^2_{\tilde{a}}$

$$S^2_{\tilde{a}} = \frac{S^2_y}{S_x^{\,2}(n-1)}$$

Учитывая нормальность распределения СВ ***y***, и линейную СВ $\tilde{a}$ от ***y*** можно утверждать что

$$\tilde{a} \sim N\left(a, \frac{\sigma_y^2}{(n-1)S_x^2}\right)$$

Вместо дисперсии $\tilde{a}$ применяем ее оценку , поэтому переходим к распределению Стьюдента

$$\frac{(\tilde{a} - a)}{\sqrt{\dfrac{S_y^2}{(n-1)S_x^2}}} \sim t_{n-2}$$

Число степеней свободы для распределения Стьюдента = число независимых величин n - число оцененных параметров : 2 (для линейной зависимости оценили два параметра a и b)

Доверительный интервал для параметра a

Если знаем, что

$$\frac{(\tilde{a} - a)}{\sqrt{\dfrac{S_y^2}{(n-1)S_x^2}}} \sim t_{n-2}$$

То

1) можем строить доверительные интервалы для **a**

$$a \in \left(\tilde{a} - \sqrt{\frac{S_y^2}{(n-1)S_x^2}}\, t_{n-2,1-\alpha/2};\ \tilde{a} + \sqrt{\frac{S_y^2}{(n-1)S_x^2}}\, t_{n-2,1-\alpha/2}\right),$$

с доверительной вероятностью $P = 1 - \alpha$

и

2) проверять гипотезы о значении **a**

Проверка гипотезы о равенству нулю параметра a

Гипотеза **a**=0
равносильна утверждению, что **y** не зависит <u>линейно</u> от x

Проверим гипотезу ***H_0: a=0***
против гипотезы ***H_1: a≠0***

Статистический критерий для проверки гипотезы H_0

$$\frac{\tilde{a}}{\sqrt{\dfrac{S_y^2}{(n-1)S_x^2}}} \sim t_{n-2}$$

или

$$\frac{\tilde{a}}{S_{\tilde{a}}} \sim t_{n-2}$$

Задаемся уровнем значимости и сравниваем наблюдаемое значение критерия с соответствующими квантилями распределения Стьюдента (табулированными значениями)

Если табулированное значение меньше, чем наблюдаемое,
то гипотеза H_0 – не справедлива и зависимость **y** от **x** есть!

Оценка дисперсии СВ $\tilde{b}$

Можно провести анализ СВ $\tilde{b}$

такой же, как для «оценка параметра ***a***»

Оценка параметра $\tilde{b}$

$$\left\{ \tilde{b} = \frac{\left(\sum_{i=1}^{n} y_i\right)}{n} - \tilde{a}\left(\frac{\sum_{i=1}^{n} x_i}{n}\right) \right.$$

Дисперсия СВ $\tilde{b}$

$$var(\tilde{b}) = \left(\frac{1}{n} + \frac{\overline{x}^2}{\sum_{i=1}^{n} (x_i - \overline{x})^2}\right)\sigma_y^2$$

Оценка дисперсии СВ $\tilde{b}$

$$S_{\tilde{b}}^2 = \left(\frac{1}{n} + \frac{\overline{x}}{\sum_{i=1}^{n} (x_i - \overline{x})^2}\right) S_y^2$$

Имея оценку дисперсии СВ $\tilde{b}$

можно оценивать ***b*** доверительным интервалом и проверять гипотезы

о значении ***b*** (так же как для параметра ***a***)