10. Проверка пригодности предлагаемой модели регрессии.

10.3. Коэффициент детерминации и коэффициент множественной регрессии

Проверяем пригодность линейной модели
Анализ выборочного коэффициента корреляции *r*

В случае линейной зависимости ***y=ax+b***

Выборочный коэффициент корреляции =+-1

Модуль 2 урок 3

$$r(x,y)=\frac{S^2(x,y)}{S(x)S(y)}=\frac{1}{n-1}\sum_{i=1}^{n}\frac{(x_i-\bar{x})}{S(x)}\frac{(ax_i-a\bar{x})}{S(ax)}=\pm 1$$

Если ***y*** и ***x*** независимые, то ***r=0***

Если ***y*** и ***x*** зависимые и ***y=ax+b***, то ***r=+-1***

Проверка зависимости ***y=ax+b*** сводится к проверка значимости (отличия ***от r 0)***

Гипотеза H_0: ***r=0***

Статистический критерий

$$\frac{r}{S_r}\sim t_{n-2}$$

$$S_r=\sqrt{\frac{1-r^2}{n-2}}$$

По правилам проверки гипотез :
не отвергаем гипотезу H_0 если

$$t_{\frac{\alpha}{2},n-2}<\frac{r\sqrt{n-2}}{\sqrt{1-r^2}}<t_{1-\frac{\alpha}{2},n-2}$$

Ранее в ***Модуле 8 урок 1*** проверяли гипотезу ***a=0*** и использовали статистический критерий

$$\frac{\tilde{a}}{\sqrt{\frac{S_y^2}{(n-1)S_x^2}}}\sim t_{n-2}$$

Можно показать, что гипотезы ***r=0*** и ***a=0*** идентичны

Коэффициент детерминации *D*

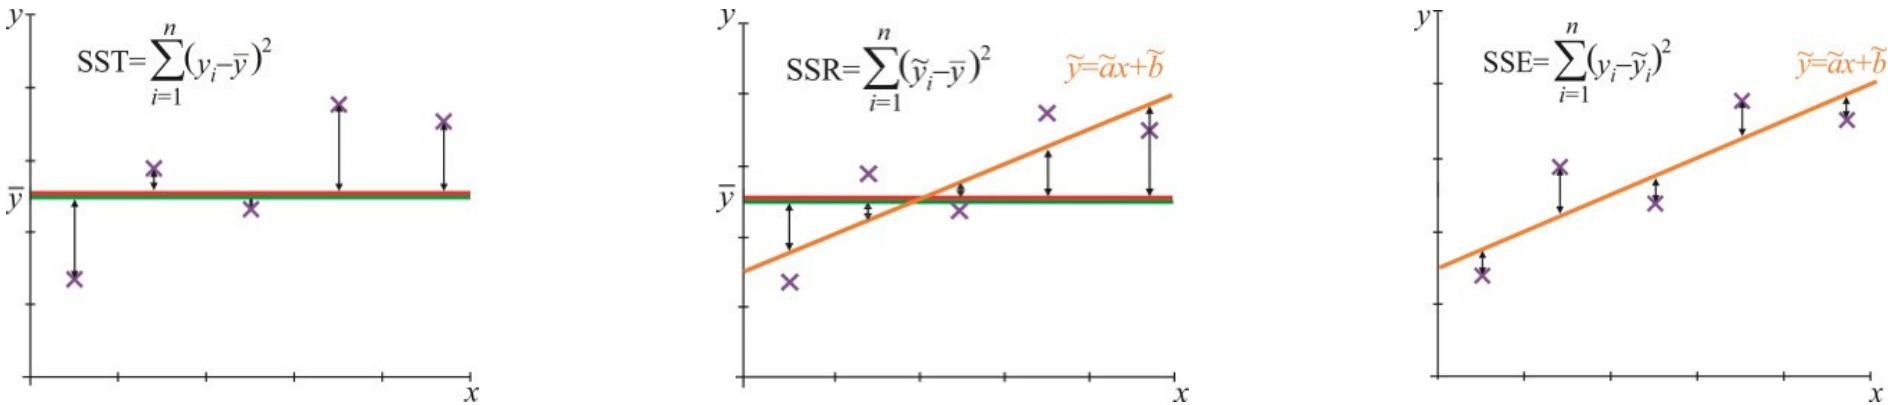

Рассматривая квадратичные отклонения, можно попытаться ответить на вопрос:
какая доля изменчивости (вариации) ***y*** связана с тем, что они имеют зависимость от факторов ***x***?
Это может определяться отношением квадратичного отклонения, вызванного наличием регрессии ***SSR*** к общему квадратичному отклонению ***SST*** (будет отношение «объясненной» части вариации ко всей вариации в целом)

$$\frac{SSR}{SST}=1-\frac{SSE}{SST}=\frac{1}{1+\frac{SSE}{SSR}}=D$$

$$D=1-\frac{\sum_{i=1}^{n}(\tilde{y}_i-y_i)^2}{\sum_{i=1}^{n}(y_i-\bar{y})^2}.$$

Коэффициентом детерминации ***D*** называют отношение «объясненной» части вариации ко всей вариации в целом.

Критерий Фишера

Отклонение : Оцененных значений от их среднего арифметического

$$\mathrm{MSR} = \frac{\mathrm{SSR}}{1} = \sum_{i=1}^{n} (\tilde{y}_i - \bar{y})^2 \sim \sigma^2 \chi_1^2$$

Отклонение: Фактических значений от оценок этих значений

$$\mathrm{MSE} = \frac{\mathrm{SSE}}{n-2} = \sum_{i=1}^{n} (\tilde{y}_i - y_i)^2 = \tilde{\sigma}^2 \sim \sigma^2 \frac{\chi_{n-2}^2}{n-2}$$

Статистический критерий:
Отношение двух величин, имеющих распределение хи-квадрат- имеет ***распределение Фишера***

$$F = \frac{MSR}{MSE} \sim F_{1,n-2}$$

Проверка по критерию Фишера равносильна проверке по критерию Стьюдента для значимости коэффициента регрессии к

Коэффициент множественной корреляции R^2

Оценка коэффициента множественной корреляции R^2 правомерна для <u>многомерных и нелинейных</u> зависимостей.

Пусть модель описывает y как произвольную функцию от x $y=f(x,\theta)$

Наличие функциональной связи $f(x)$ подразумевает совершенно однозначную связь y и x. Т. е. одному значению x соответствует только одно значение y.

При наличии погрешности экспериментальные значения будут лежать в некоторой полосе около **f(x)**.

Таким образом имеются y – экспериментальные данные и $\tilde{y}$ – подогнанные значения.

Построим график зависимости $\tilde{y}\ (\tilde{y})$ (очевидно- биссектриса угла) и $y(\tilde{y})$

График $y(\tilde{y})$ должен повторять $\tilde{y}\ (\tilde{y})$ ***(какой бы сложной не была модель y=f(x,θ)!!!)***

и если есть отклонения, то отклонения оценим как показатель расхождения модели и экспериментальных данных

Коэффициент множественной корреляции R^2

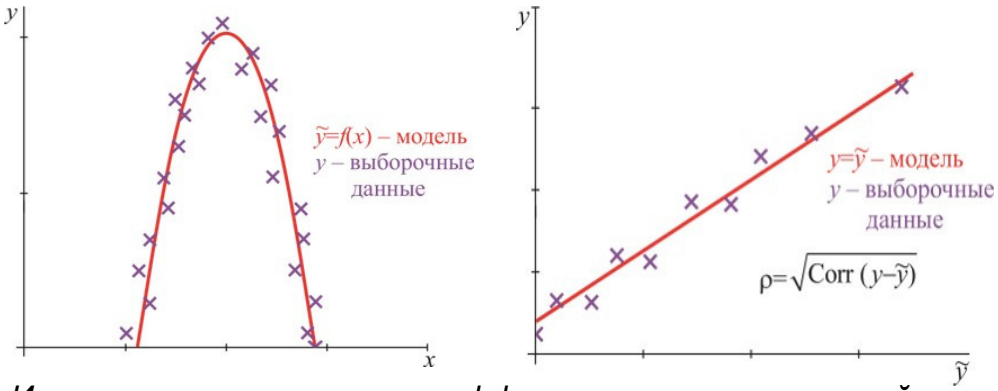

Иллюстрация к понятию коэффициента множественной регрессии:

а) выборочные данные y и модельная кривая $\tilde{y}$ в зависимости от x;

б) выборочные данные y и результаты подгонки (модельные значения $\tilde{y}$) в зависимости от $\tilde{y}$

$$R^2=corr(y,\tilde{y})$$

Качественная оценка связи модели и данных

Коэффициент множественной корреляции R – положительный корень квадратный из R^2 - между экспериментальными значениями y и полученными по модели $\tilde{y}$ при разных x.

Использование коэффициента множественной корреляции правомерно для многофакторных моделей и для сложных (нелинейных) однофакторных моделей.

В случае, если модель выбрана правильно, коэффициент множественной корреляции будет близок к 1. Чем дальше коэффициент множественной корреляции от 1, тем сомнительней использованная модель.

шкала Чеддока

коэффициент корреляции	качественная оценка связи
0,1-0,3	Слабая
0,3-0,5	Умеренная
0,5-0,7	Заметная
0,7-0,9	Высокая
0,9-0,99	Весьма высокая

Для моделей зависимостей, в которых <u>есть линейная зависимость от параметров или зависимость близка к линейной,</u> квадрат коэффициента множественной корреляции равен коэффициенту детерминации.

$$R^2 = D$$